Desarrollo de un sistema inteligente basado en IoT y Redes Neuronales para la Predicción y Simulación de la Calidad del Aire en Culiacán, Sinaloa.

Integrantes: Pacheco Perez Diego , Ramos Villa Ignacio

Docente: Zuriel Dathan Mora Felix

Materia: Tópicos selectos de Inteligencia Artificial

Grupo: 10:00 – 11:00

Tabla de contenido

1. **Introducción** 3

2. **Antecedentes del Problema** 4

3. **Planteamiento del Problema** 4

4. **Objetivos**..... 5

    4.1 Objetivo General 5

    4.2 Objetivos Específicos..... 5

5. **Justificación**..... 5

6. **Marco Teórico** 6

    6.1 Marco Histórico..... 6

7. **Metodología**..... 6

    7.1 Tipo de Estudio..... 6

7.2 Metodología de Desarrollo 6

8. Alcance y Limitaciones..... 8

8.1 Alcances..... 8

8.2 Limitaciones..... 8

9. Resultados Esperados..... 8

10. Referencias Bibliográficas..... 9

1. Introducción

La contaminación atmosférica representa uno de los principales desafíos ambientales y de salud pública a nivel mundial. En México, aunque ciudades como la Zona Metropolitana del Valle de México han sido ampliamente estudiadas, ciudades intermedias como Culiacán, Sinaloa presentan problemáticas emergentes relacionadas con:

- Crecimiento urbano acelerado
- Alta densidad vehicular
- Actividades agrícolas en zonas periféricas
- Quema de residuos agrícolas
- Condiciones climáticas extremas (altas temperaturas y baja dispersión de contaminantes)

En Culiacán, los niveles de material particulado ($PM_{2.5}$ y PM_{10}) pueden incrementarse durante temporadas secas y periodos de quema agrícola, generando riesgos para la salud respiratoria de la población.

En este contexto, la integración de Inteligencia Artificial (IA) **e** Internet de las Cosas (IoT) permite evolucionar de sistemas reactivos hacia modelos predictivos capaces de anticipar episodios críticos de contaminación.

El presente proyecto propone el desarrollo de un sistema inteligente basado en sensores IoT y redes neuronales tipo LSTM para predecir niveles de contaminación atmosférica y simular estrategias de mitigación en Culiacán, Sinaloa.

2. Antecedentes del Problema

En Sinaloa, el monitoreo de la calidad del aire ha sido limitado en comparación con grandes zonas metropolitanas del país. La información disponible suele ser parcial o no contar con suficiente resolución espacial.

Factores locales que influyen en la contaminación en Culiacán:

- Alta circulación vehicular en avenidas principales (ej. Álvaro Obregón, Universitarios, Pedro Infante).
- Actividad agrícola en el valle de Culiacán.
- Quema de rastrojo.
- Polvo suspendido en temporadas secas.
- Condiciones climáticas con altas temperaturas que favorecen la formación de ozono (O_3).

A nivel internacional, investigaciones han demostrado que el uso de Machine Learning permite predecir picos de contaminación con hasta 24 horas de anticipación.

Modelos LSTM han demostrado ser especialmente efectivos para modelar series temporales ambientales debido a su capacidad para capturar dependencias a largo plazo.

Según la Organización Mundial de la Salud (2021), la contaminación del aire causa aproximadamente 7 millones de muertes prematuras al año, lo que evidencia la urgencia de soluciones preventivas también en ciudades medias como Culiacán.

3. Planteamiento del Problema

Aunque Culiacán no cuenta con la misma infraestructura de monitoreo que otras grandes ciudades mexicanas, presenta condiciones que favorecen episodios de contaminación:

- Elevadas temperaturas.
- Baja velocidad del viento en ciertos periodos.
- Alta actividad vehicular.
- Actividad agrícola periurbana.

El problema radica en que no existe una infraestructura predictiva que procese datos multivariables para anticipar episodios críticos y evaluar escenarios de mitigación.

4. Objetivos

4.1 Objetivo General

Desarrollar un sistema inteligente basado en IoT y redes neuronales LSTM para monitorear, predecir y simular medidas de mitigación de contaminantes atmosféricos en Culiacán, Sinaloa.

4.2 Objetivos Específicos

- Procesar un conjunto de datos históricos de al menos 2 años de variables ambientales y meteorológicas en Culiacán.
- Identificar las 3 zonas con mayor concentración promedio de $PM_{2.5}$ dentro del área urbana.
- Implementar un modelo predictivo LSTM multivariado con horizonte de predicción de 24 horas.
- Simular escenarios de reducción vehicular o disminución de quema agrícola.

5. Justificación

Aunque Culiacán no se encuentra entre las ciudades más estudiadas en contaminación del aire, su crecimiento urbano y actividad agrícola la convierten en una ciudad vulnerable.

La integración de IoT e Inteligencia Artificial permitiría:

- Generar alertas preventivas locales.
- Apoyar decisiones municipales sobre movilidad.
- Reducir exposición en escuelas y hospitales.
- Generar información científica local para políticas públicas.

Además, el proyecto es viable debido a:

- Disponibilidad de datos meteorológicos abiertos.
- Bajo costo actual de sensores IoT.

6. Marco Teórico

6.1 Marco Histórico

La aplicación de la Inteligencia Artificial al estudio de la atmósfera ha evolucionado de modelos estadísticos tradicionales hacia sistemas de aprendizaje profundo.

Uno de los proyectos pioneros fue U-Air, desarrollado por Yu Zheng en Microsoft Research Asia, donde se demostró que redes neuronales podían inferir niveles de $PM_{2.5}$ en zonas sin sensores físicos mediante datos de tráfico y meteorología.

El proyecto DeepAir desarrollado por Google y Aclima demostró que la contaminación varía significativamente incluso dentro de una misma calle, lo que valida la necesidad de monitoreo distribuido.

En Europa, el Proyecto PULSE, financiado por Horizonte 2020, integró modelos de IA para correlacionar exposición a contaminantes con datos de salud pública.

Posteriormente, el proyecto City-Scanner del MIT introdujo la metodología de sensores móviles de bajo costo, demostrando que la IA puede filtrar el "ruido" de sensores económicos para obtener datos confiables.

Asimismo, estudios recientes demuestran que las redes neuronales LSTM son particularmente efectivas para modelar series temporales ambientales, ya que permiten capturar dependencias a largo plazo en datos climáticos y urbanos.

7. Metodología

7.1 Tipo de Estudio

Enfoque: Cuantitativo
Alcance: Descriptivo-Correlacional

7.2 Metodología de Desarrollo

Se utilizará la metodología CRISP-DM(Cross-Industry Standard Process for Data

Mining). **7.2.1 Comprensión del entorno**

- Análisis de límites máximos permisibles establecidos por la OMS. •

Identificación de actores locales: Ayuntamiento de Culiacán, Secretaría de Desarrollo Sustentable de Sinaloa.

7.2.2 Comprensión de datos

- Datos atmosféricos: $PM_{2.5}$, PM_{10}, NO_2 y O_3.
- Datos meteorológicos: temperatura, humedad, velocidad del viento.
- Datos de movilidad urbana.

7.2.3 Preparación de datos

- Limpieza de lecturas erróneas.
- Normalización de variables.
- Ingeniería de características (ej. índices de riesgo horario).

7.2.4 Modelado

Se entrenará una red neuronal LSTM para predicción de series

temporales. Se optimizarán hiperparámetros como:

- Número de capas ocultas.
- Tasa de aprendizaje.
- Tamaño de ventana temporal.

7.2.5 Evaluación

Se medirá el desempeño predictivo mediante:

- MAE
- RMSE
- R^2

7.2.6 Simulación de Mitigación

Se desarrollará un módulo de simulación basado en escenarios hipotéticos (“what-if”), donde se modelará la posible reducción de concentración contaminante ante:

- Reducción del flujo vehicular en horas pico.
- Restricción temporal en zonas céntricas.
- Disminución hipotética de quema agrícola.
- Alertas preventivas en temporadas de altas temperaturas.

8. Alcance y Limitaciones

8.1 Alcances

- Desarrollo de un modelo predictivo basado en redes neuronales LSTM para estimar concentraciones de $PM_{2.5}$, PM_{10}, NO_2 y O_3.
- Diseño conceptual de una arquitectura IoT para recolección de datos en tiempo real.
- Simulación de escenarios de mitigación mediante modelos "what-if".
- Evaluación del desempeño predictivo utilizando métricas cuantitativas (MAE, RMSE y R^2).

8.2 Limitaciones

- No se implementará físicamente la red completa de sensores IoT.
- Dependencia de la calidad y disponibilidad de datos abiertos.
- No se realizarán pruebas clínicas directas.
- La simulación será teórica y no implicará intervención real.

9. Resultados Esperados

Se espera que el modelo desarrollado:

- Se espera que el modelo alcance un nivel de precisión competitivo respecto a estudios previos, con errores dentro de rangos aceptables reportados en la literatura (10–20%) sujeto a la calidad y disponibilidad de datos locales.
- Permita evaluar el impacto potencial de restricciones vehiculares temporales.
- Contribuya al diseño de estrategias de monitoreo inteligente en Culiacán.

Asimismo, se espera demostrar que la integración de IoT e Inteligencia Artificial puede fortalecer los sistemas tradicionales de monitoreo ambiental.

10. Referencias Bibliográficas

1. Arroyo, P., et al. (2020). Artificial intelligence for air quality forecasting: A review. *Journal of Environmental Management, 266*, 110–122.
2. CRISP-DM Consortium. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.
3. Instituto Nacional de Ecología y Cambio Climático. (2022). *Informe nacional de calidad del aire en México*. Gobierno de México.
4. Organización Mundial de la Salud. (2021). *WHO global air quality guidelines*. WHO Press.
5. Zheng, Y., Liu, F., & Hsieh, H. P. (2013). U-Air: When urban air quality inference meets big data. *Proceedings of the 19th ACM SIGKDD*, 1436–1444.
6. Apte, J. S., et al. (2017). High-resolution air pollution mapping with Google Street View cars. *Environmental Science & Technology, 51*(12), 6999–7008.